

ANÁLISE DE SÉRIES TEMPORAIS UTILIZANDO A TRANSFORMADA DE WAVELET. APLICAÇÕES NO DIAGNÓSTICO DE FALHAS DE MOTORES DE INDUÇÃO

SÉRGIO CORDEIRO

RESUMO. Este trabalho aborda a análise de séries temporais por meio da Transformada de Wavelet para o diagnóstico e para o prognóstico de falhas em motores de indução, que são as máquinas rotativas predominantes na área industrial.

Palavras-chave: CBM, Manutenção Baseada em Condição, Manutenção Preditiva, Transformada de Wavelet, Análise de Séries Temporais, Máquinas Rotativas, Motores de Indução, Diagnóstico Automatizado.

1. INTRODUÇÃO

Os últimos anos testemunharam uma mudança profunda na estratégia de manutenção adotada pela indústria, em favor da chamada Manutenção Preditiva, ou Manutenção Baseada em Condição (CBM: *Condition Based Maintenance*). Essa abordagem se baseia no monitoramento em tempo real do maquinário, de forma a obter-se diagnóstico preciso de tendência a falhas. Tal diagnóstico subsidia a programação e a otimização da manutenção, com o objetivo de evitar falhas imprevistas e manter os custos da manutenção em limites aceitáveis. Além do diagnóstico, que aponta falhas iminentes, é desejável que as técnicas executem também um prognóstico, que aponta as ações corretivas e os resultados esperados. Uma ampla descrição das técnicas de diagnóstico e prognóstico podem ser encontradas em [?] e [AAYAZ 2014]. Mais considerações sobre CBM e sua relação com outras técnicas de manutenção pode ser encontrado em [APRAKASH 2014].

A análise de sinais é uma das ferramentas mais importantes nesse contexto. Seu objetivo é extrair, sintetizar e interpretar a informação contida em sinais provenientes de sensores instalados nas máquinas. A Transformada Rápida de Fourier (FFT) é uma das técnicas mais bem estabelecidas e mais usadas. Ela oferece baixo custo computacional e permite fácil análise de sinais estacionários.

Entre os equipamentos industriais, as máquinas rotativas ocupam posição de destaque, pela sua importância e ubiquidade. E nestas, os motores de indução são de longe o tipo de motor mais empregado, pela sua simplicidade, robustez e baixo custo.


[APEZZANI 2015] lista as principais causas de defeitos em motores de indução, em função de pesquisa do *Electric Power Research Institute* (EPRI):

- Mancais: 40%
- Enrolamento: 38%
- Rotor: 10%
- Outras: 12%

O motor de indução, pela sua robustez, consegue continuar funcionando por muito tempo depois do surgimento dos defeitos mais comuns. Isso configura grande uma oportunidade para o monitoramento de condição. Entre as técnicas de diagnóstico, as wavelets se destacam pela sua capacidade de manter alta resolução em ampla faixa de frequências de análise. Com isso, prestam-se melhor que a FFT à análise de sinais não-estacionários. Componentes não-estacionários nos sinais são comuns, devido a mudanças nas condições operacionais ou como consequência dos próprios defeitos sob análise. Em vista disso, tais componentes contêm uma grande quantidade de informação, que se deve tratar com as ferramentas apropriadas.

2. DEFEITOS

As figuras abaixo mostram os elementos construtivos de um rotor de gaiola típico: barras de rotor (*rotor bar*), eixo (*shaft*), anéis de fechamento (*end ring*), aletas de ventilação (*fan*), etc.



Fonte: [AFig1]

A respeito da quebra de barras na gaiola, que é um dos defeitos mais comuns que incidem sobre o rotor, citamos [APEZZANI 2015]:

A detecção precoce de uma barra rompida no rotor minimiza os danos ao motor e reduz os custos de reparo. Em alguns casos, a condição de uma barra rompida começa com uma trinca na junção entre a barra do rotor e o anel

da extremidade como resultado de estresse térmico e mecânico [3]¹. Esses estresses são mais significativos durante a partida de motores com cargas de alta inércia. A flexão de uma barra trincada devido a variações na temperatura provoca o rompimento da barra. Quando uma barra rompe, as barras adjacentes conduzem correntes superiores aos respectivos valores de projeto, causando mais danos se a condição de barra rompida não for imediatamente detectada. As correntes entre as barras que aparecem em função da barra rompida afetam a evolução da falta no rotor, causando danos nas laminações do núcleo do rotor [3]¹. A análise da assinatura da corrente do motor (“Motor Current Signature Analysis” – MCSA) é o método mais popular para detecção de faltas na gaiola do rotor [4]² [5]³. Este método efetua a análise do espectro de frequência das correntes do estator para determinar as condições eletromecânicas do motor e equipamentos acionados. Quando ocorre a ruptura de uma ou mais barras, bandas laterais superior e inferior aparecem em $(1 \pm 2s)f_o$, onde s é a frequência de escorregamento do motor e f_o é a frequência do sistema [6]⁴. As magnitudes dessas bandas laterais aumentam com o número de barras rompidas. Com base nisso, a Schweitzer disponibiliza um relé capaz de acusar rompimento de barras no rotor, que analisa a corrente do estator por meio da Transformada de Fourier. De acordo com [APEZZANI 2015], o algoritmo não funciona bem para cargas leves, porque o escorregamento é muito pequeno nesse caso.

3. REVISÃO BIBLIOGRÁFICA

[?] é uma obra bastante abrangente e muito citada, mas não trata especificamente da Transformada de Wavelet

¹A. H. Bonnett and G. C. Soukup, “Analysis of Rotor Failures in Squirrel-Cage Induction Motors,” IEEE Transactions on Industry Applications, vol. 24, no. 6, pp. 1124–1130, novembro/dezembro 1988.

²H. Penrose, Electrical Motor Diagnostics, 2nd ed. Success by Design, maio de 2008.

³G. B. Kliman, R. A. Koegl, J. Stein, R. D. Endicott, and M. W. Madden, “Noninvasive Detection of Broken Rotor Bars in Operating Induction Motors,” IEEE Transactions on Energy Conversion, vol. 3, no. 4, pp. 873–879, dezembro de 1988.

⁴W. Deleroi, “Der Stabbruch im Käfigläufer eines Asynchronmotors, Teil 1: Beschreibung mittels Überlagerung eines Störfeldes,” Archiv Für Elektrotechnik, vol. 67, pp. 91–99, 1984.

nem de máquinas rotativas. Tal foco está presente tanto em [APENG 2004] quanto em [?], que por esse motivo foram mais consultados na pesquisa; pode-se, até certo ponto, entender este último artigo como uma atualização do anterior. [?] relata alguns desenvolvimentos recentes na teoria de wavelets e novas aplicações da técnica em CBM surgidas no período (2004-2014). [APENG 2004] havia feito o mesmo para o período (1990-2004). Outra resenha consultada foi [APRAKASH 2014].

[AAYAZ 2014] é uma resenha um pouco diferente, voltada para a exploração dos fundamentos matemáticos das técnicas de diagnóstico. A análise de wavelets é uma das investigadas.

A maioria das aplicações consolidadas, não apenas da Transformada de Wavelets, mas de todas as técnicas de análise de sinais, se refere ao diagnóstico de defeitos mecânicos. [APENG 2004] cita apenas uma aplicação referente a diagnóstico de defeitos elétricos em motores de indução; esse número cresce para 4 em [APRAKASH 2014] e 5 em [?]. [ASZABO 2004] detalha uma dessas aplicações: o emprego da DWT na análise da assinatura de corrente de motores (MCSA: *Motor Current Signature Analysis*) de indução de rotor bobinado trifásico de 3 kW. Mediram-se as correntes sob diversos regimes de carga e em condições normais e na presença da falta de uma fase no rotor. Foram escolhidos a wavelet de Daubechies e o toolbox de wavelets do MATLAB para analisar os sinais. O defeito de manifestou na faixa de frequências de 32 a 64 Hz. A manifestação é menos clara quando o motor está menos carregado. No entanto, os autores não compararam seus resultados com os da ferramenta mais tradicional, a FFT; além disso, a falha estudada foi do tipo imprevisível, que não se presta a prevenção via CBM. Por outro lado, o estudo possui a virtude de ter usado equipamentos reais, em lugar de meramente simulados.

[AKAHN 2010] oferece um panorama de todas as técnicas em voga para diagnóstico de falhas em motores elétricos, e em seguida passa a focar as baseadas em wavelets, inclusive algumas que conjugam a elas ferramentas de inteligência artificial, como ANNs e SVMs. Depois descreve em detalhes uma aplicação real, que emprega a wavelet de Daubechies para analisar a corrente de estator em alguns motores elétricos; entre eles, um de gaiola de 1 hp e outro

de rotor bobinado de 1.5 hp. O trabalho mostrou que o vetor de características permite não apenas detectar defeitos, mas classificá-los entre falta de fase e curto para terra. Tanto a detecção quanto a classificação foram feitas por uma rede neural. Apesar dos méritos desse estudo, trata-se também de defeitos que não interessam ao processo de CBM.

[ABOUZIDA 2013] é outro estudo bem-sucedido sobre uso de wavelets e MCSA com motores reais de 4 kW, visando diagnosticar barras ou anéis quebrados no rotor e curto-circuito no estator. Coletaram-se amostras de correntes e tensões, bem como da velocidade de rotação. Verificou-se que focar nas baixas frequências elimina qualquer influência de vibração sobre o diagnóstico.

[ASHI 2013 1] compara o desempenho das wavelets de Daubechies 8, 9 e 10, e de Symlet 7 e 8 no contexto do diagnóstico de barras de rotor quebradas em motores trifásicos de 5.5 kW, por meio da análise da corrente do estator, em condições de carga variável. Em vez de um TC, foi usado um sensor de efeito Hall na aquisição de dados; a frequência de amostragem foi 1.92 kHz. Os defeitos foram diagnosticados no quinto nível de detalhe após a aplicação de técnicas estatísticas ao vetor de características; todas as wavelets testadas se comportaram satisfatoriamente, com a de Symlet 8 apresentando o melhor desempenho.

[ANGOTE 2014] apresenta uma abordagem nova, que consiste em analisar não a corrente de estator, mas o que os autores chamam "corrente residual", que é a diferença entre a corrente e sua média ao longo de vários ciclos. A corrente residual apresenta a vantagem de seu espectro conter apenas componentes relacionadas com aspectos mecânicos do motor. A plataforma empregou motores de 3kW com tacômetros óptico, frequência de amostragem de 25.6 kHz, 10 níveis de decomposição e a wavelet de Daubechies 5. Não foi usado um rotor defeituoso neste caso; o defeito foi simulado por meio da adição de uma resistência de 40 m Ω em série com uma das fases. Os autores não conseguiram distinguir com segurança, usando a corrente de estator, a assinatura de um motor com defeito da de um sem defeito. Com a corrente residual, no entanto, uma detecção confiável foi possível.

A dificuldade em distinguir com segurança a assinatura de um motor defeituoso da de um motor são levou [ASHI

2013 2] a associar a análise de wavelets a uma ferramenta de inteligência computacional, a rede neural probabilística (PNN: *Probability Neural Network*), criando o que chamar de wavelets neural network. Em tal rede neural, as funções de ativação dos neurônios da camada escondida são baseadas em wavelets. O treinamento não foi feito pelo algoritmo usual de *backpropagation*, e sim pelo de cardumes (PSO: *Particle Swarm Optimization*), que é um algoritmo evolucionário. A plataforma foi montada com motores de 3.7 kW com número de barras quebradas variável, e submetidos a cargas variadas. Foi usada a wavelet de Daubechies 10, com frequência de amostragem de 1 kHz. Para composição do vetor de características, foram empregados não os valores da energia em cada banda, mas medidas estatísticas como média, média absoluta, mediana e seus respectivos desvios. Segundo os autores, o sistema de diagnóstico, além de preciso, precisava ser rápido o bastante para produzir respostas em tempo real.

[ASESHADRINATH 2014] alega que as redes neurais apresentam um grande inconveniente, que é a dificuldade de sintonizarem-se os seus múltiplos parâmetros, e defende o emprego de uma estrutura otimizada por meio de algoritmos de otimização (mínimos quadrados) e genéticos, seguida de um classificador baseado em filtro Bayesiano. O problema prático estudado foi o diagnóstico de curtos entre espiras no enrolamento do estator, também por meio da análise da assinatura de corrente. As falhas em questão causam assimetria na impedância da máquina e produzem correntes de sequência negativa; mas tal condição é também causada por assimetrias na carga, o que dificulta o diagnóstico. Outra dificuldade, segundo os autores, é que a técnica de wavelets é sensível a deslocamento e insensível, em alguns casos, a oscilações do sinal; por essa razão, foi usada a DTCWT, que não apresenta esses problemas. O vetor de características usado é composto apenas pela energia espectral na 13ª decomposição. A plataforma empregou motores de 5 HP, sob condições de carga variável, a wavelet de Daubechies 10 como mãe e uma frequência de amostragem de 12.5 kHz. A DTCWT apresentou maior sensibilidade e seletividade que a DWT no caso estudado.

4. WAVELETS

A Transformada de Wavelets é uma ferramenta matemática que converte um sinal do domínio do tempo para um domínio misto tempo/frequência, ou tempo/escala-de-tempo, como também se diz. Para tanto, o sinal é decomposto em uma série de wavelets, cada uma delas com uma amplitude e uma frequência determinadas, mas com a mesma forma geral; tal forma geral é frequentemente chamada de wavelet-mãe, e as wavelets geradas a partir dela, wavelets-filhas ou família de wavelets. A wavelet-mãe deve ser selecionada de acordo com a aplicação. Para que uma função matemática possa servir como wavelet, ela deve cumprir pelo menos os seguintes requisitos:

1. ter caráter oscilatório
2. concentrar sua energia em um curto período de tempo
3. sua média no tempo ser nula

A formulação inicial foi dada por Morlet e Grossman em 1984. Em 1985, Meyer construiu uma wavelet-mãe que oferecia boas propriedades matemáticas tanto com relação ao tempo quanto com relação à frequência. Em 1986, Meyer e Mallat desenvolveram a ideia da Análise com Múltipla Resolução (MRA: *Multi-resolution Analysis*), que facilita a tarefa de obter wavelets-mãe ortogonais. Pouco tempo depois, conseguiu-se descobrir um algoritmo para a versão digital.

As Transformadas de Wavelets podem ser categorizadas como:

- a) Transformada de Wavelet Contínua (CWT: *Continuous Wavelet Transform*)
- b) Transformada de Wavelet Discreta (DWT: *Discrete Wavelet Transform*)
- c) Transformada de Wavelet Empacotada (WPT: *Wavelet Packet Transform*)
- d) Transformada de Wavelet de Segunda Geração (SGWT: *Second Generation Wavelet Transform*)
- e) Transformada de Wavelet Contínua em Árvore Dupla (DTCWT: *Dual-Tree Continuous Wavelet Transform*)
- f) Undecimated discrete wavelet transform (UDWT)

4.1. CWT. A CWT de um sinal $x(t)$, aqui denotada por $\chi(s, \tau)$, é dada pela correlação do sinal com a família de

wavelets $\Psi^*\left(\frac{t}{s}\right)$ geradas a partir da wavelet-mãe $\psi(t)$ ¹:

$$(1) \quad \chi(s, \tau) = \frac{1}{\sqrt{s}} \int_{-\infty}^{\infty} x(t) \Psi^*\left(\frac{t-\tau}{s}\right) dt \quad s, \tau \in \mathbb{R} \wedge s > 1$$

onde * indica conjugado complexo. Em 1, s pode ser entendido como um fator de escala e τ , como um deslocamento no tempo. O fator normalizador \sqrt{s} é importante porque faz com que todas as wavelets-filhas possuam a mesma energia. A wavelet-mãe deve ser centrada em $t = 0$.

A Transformada de Wavelets é similar à Transformada de Fourier, ao representar um sinal como uma soma de componentes, apenas com a família de wavelets substituindo as funções senoidais no papel de bases ortonormais.

A Transformada de Fourier de $\chi(s, \tau)$, que projeta a CWT no domínio da frequência real, é dada por ²:

$$\begin{aligned} \hat{\chi}(s, f) &= \mathcal{F}\{\chi(s, \tau)\} \\ &= \frac{1}{2\pi\sqrt{s}} \int_{-\infty}^{\infty} \left[\int_{-\infty}^{\infty} x(t) \Psi^*\left(\frac{t-\tau}{s}\right) dt \right] e^{-2\pi f \tau} d\tau \\ (2) \quad &= \sqrt{s} \hat{X}(f) \hat{\Psi}^*(sf) \end{aligned}$$

(3)

onde $\hat{\cdot}$ denotada a Transformada de Fourier. A partir de 2, é possível obter a transformação inversa, projetando a CWT no domínio do tempo:

$$\begin{aligned} \chi(s, \tau) &= \mathcal{F}^{-1}\{\hat{\chi}(s, f)\} \\ &= \mathcal{F}^{-1}\{\sqrt{s} \hat{X}(f) \hat{\Psi}^*(sf)\} \\ (4) \quad &= \sqrt{s} x(t) * \mathcal{F}^{-1}\{\hat{\Psi}^*(sf)\} \end{aligned}$$

(5)

A equação 4 corresponde a um filtro passa-faixa cuja resposta em frequência é dada por $\hat{\Psi}(sf)$.

Do ponto de vista físico, o módulo de χ corresponde à energia de $x(t)$. Um gráfico do quadrado desse módulo é chamado **escalograma**, e encontra amplo uso no diagnóstico de defeitos. A fase de χ , por sua vez, indica com grande precisão os momentos em que acontecem descontinuidades no sinal.

¹Alguns autores escrevem $|s|$ no lugar de s , mas isso é desnecessário porque s nunca é negativo

²Aqui se empregou a chamada versão normalizada da Transformada de Fourier

A transformada χ será real sempre que sua densidade espectral for limitada:

$$(6) \quad \int_{-\infty}^0 \frac{|\hat{\chi}(s, f)|^2}{|f|} df = \int_0^{\infty} \frac{|\hat{\chi}(s, f)|^2}{|f|} df = C \quad C \in \mathcal{C}^*$$

4.2. DWT e WPT. A DWT é uma discretização da CWT que consiste em tomar apenas valores de s e τ tais que:

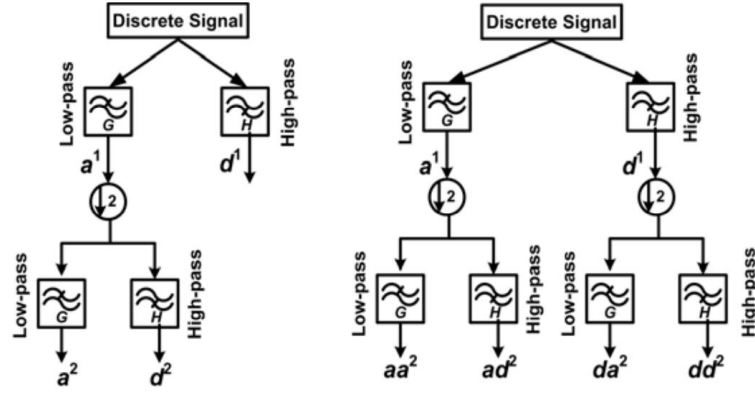
$$(7) \quad \begin{aligned} s &= s_0^m & n, m &\in \mathbb{N} \\ \tau &= n\tau_0^n & s_0 &> 1 \\ & & \tau_0 &> 0 \end{aligned}$$

mantendo a fórmula 1.

As wavelets-filhas são ortogonais se s_0 e τ_0 forem bem escolhidos. O valor mais comum para s_0 e τ_0 é 2. Tal discretização é chamada diádica.

A DWT exige menos esforço computacional que a CWT, ao custo de alguma perda de informação. Uma maneira de se obter a DWT de um sinal, por meio de filtros espelhados em quadratura (QMF: *Quadrature Mirror Filter*) é descrita em MALLAT 1989. A primeira filtragem gera uma sequência $a^1[n]$ de coeficientes de baixa frequência e outra, $d[n]$, de coeficientes de alta frequência; novas etapas aplicadas aos coeficientes de baixa frequência geram as sequências $a^p[n]$ e $d^p[n]$, sendo p o número de filtrações. A cada filtragem, o comprimento das sequências cai pela metade, porque são descartadas as amostras que se tornaram redundantes de acordo com o teorema da amostragem. As sequências a são chamadas aproximações, e as sequências d , detalhes.

A WPT é uma variação da DWT, desenvolvida em 1992 por Coifman, Meyer e Wickerhauser, em que os componentes de alta frequência também são decompostos. As sequências resultantes de cada etapa de filtragem são chamadas $aa^p[k]$, $ad^p[k]$, $da^p[k]$ e $dd^p[k]$, sendo p o número da etapa. O processo está descrito em ???. A WPT permite decompor o mesmo sinal em mais de uma maneira, proporcionando uma representação mais adaptável ao problema a resolver.



a) Geração da DWT b) Geração da WPT

A WPT pode ser escrita como uma equação:

$$(8) \quad \text{WPT}[j, k, t] = 2^{\frac{j}{2}} \text{DWT}[2^j t - k]$$

Uma das aplicações da WPT é a extração de características do sinal, por meio da montagem de um vetor de características (*feature vector*) \mathbf{v} , que é um autovetor de energia do sistema, dado por:

$$(9) \quad \mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v \end{bmatrix} \quad v_i = \sqrt{\frac{1}{N_p} \sum_{k=1}^{N_p} b_i[k]^p}$$

onde p é o nível de decomposição escolhido, b_i^p são os coeficientes da sequência e N_p é o número de amostras nesse nível. Por exemplo, para as sequências de nível 2:

$$(10) \quad \mathbf{v} = \begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix} \quad \begin{aligned} v_1 &= \sqrt{\frac{2}{N} \sum_{k=1}^{\frac{N}{2}} aa^2[n]} \\ v_2 &= \sqrt{\frac{2}{N} \sum_{k=1}^{\frac{N}{2}} ad^2[n]} \\ v_3 &= \sqrt{\frac{2}{N} \sum_{k=1}^{\frac{N}{2}} da^2[n]} \\ v_4 &= \sqrt{\frac{2}{N} \sum_{k=1}^{\frac{N}{2}} dd^2[n]} \end{aligned}$$

4.3. **SGWT.** A SGWT é um alternativa à DWT que obtém os coeficientes por meio de uma operação conhecida como

lifting, em lugar de filtragem, como é o caso da DWT. O processo é descrito em [SWELDENS 1998] e [CLAYPOOLE 1999]. O *lifting* proporciona uma otimização, no sentido de capturar a maior quantidade de informação com o mínimo de coeficientes. A implementação é mais fácil e computacionalmente mais barata que a da DWT.

4.4. DTCWT. Todas as variantes da CWT anteriores possuem a característica indesejável de apresentar variações grandes nos coeficientes em função de pequenos deslocamentos no sinal de entrada. Isso se deve à natureza não-linear dos processos de amostragem, *lifting*, etc. A DTCWT não apresenta essa característica, por isso vem sendo apontada como uma boa alternativa para análise de transientes.

A DTCWT emprega duas estruturas paralelas de DWT, uma para a parte real e a outra para a parte imaginária. As respostas em frequência $\hat{G}_r(\omega)$ e $\hat{G}_i(\omega)$ dos filtros passa-baixa que gerarão as sequências real e imaginária, respectivamente, devem obedecer à expressão:

$$(11) \quad |\hat{G}_r(\omega)| = |\hat{G}_i(\omega)|$$

$$(12) \quad \arg \left(\hat{G}_r(\omega) \right) = \arg \left(\hat{G}_i(\omega) \right) + 0.5\omega$$

(13)

Nessas condições, teremos a seguinte relação entre as wavelets-mãe para as duas estruturas:

$$(14) \quad \Psi_i(t) \approx \mathcal{H}\{\Psi_r(t)\}$$


(15)

onde \mathcal{H} denota a Transformada de Hilbert.


4.5. Escolha da wavelet-mãe. A escolha ótima da função wavelet-mãe é objeto de pesquisa constante. Em geral, são usadas técnicas estatísticas e de otimização na seleção. Em alguns casos, a wavelet não é escolhida a partir de funções matemáticas conhecidas, e sim construída numericamente a partir da resposta ao impulso do sistema a ser analisado. Também é possível usar mais de uma wavelet-mãe ao mesmo tempo.

É desejável que as wavelets-filhas sejam funções ortogonais. O processo conhecido de geração de tais funções

funciona apenas para $s \leq 1$, por isso é preciso gerar uma função associada, $\phi(t)$, que é conhecida como **função de escalamento**, e que é usada para obter os valores para $s > 1$. Ambas as funções carregam a mesma informação, $\phi(t)$ no intervalo $f \in [0, \pi]$ e $\psi(t)$ no intervalo $f \in [\pi, 2\pi]$. As figuras abaixo são um exemplo de tais funções: a wavelet de Daubechies e sua associada.



- a) Wavelet de Daubechies b) Função de escalamento associada
- Em algumas aplicações, é necessário que as wavelets-filhas sejam reais e simétricas. Uma maneira de resolver esse problema é usar duas famílias de funções, uma para a decomposição e outra para a reconstrução do sinal. Um exemplo, a chamada wavelet *Spline*, é ilustrada abaixo.



- a) Wavelet de Daubechies b) Função de escalamento associada
- [ASHI 2013 1] compara o desempenho de algumas wavelets-mãe no contexto do diagnóstico de barras de rotor de gaiola quebradas. Um dos critérios existentes para escolha de wavelets-mãe é o *minimum description length data*, descrito por [HAMID 2002]. Isso dito, citamos [APRAKASH 2014]:

Currently there is no any theoretical guidelines for selecting optimum wavelet basis or selecting there corresponding shape parameter and scale level for a particular application this is done only by trial or error.

4.6. Escolha de outros parâmetros. O emprego da Transformada de Wavelets exige a escolha acertada dos parâmetros de aquisição de dados e de geração das sequências: taxa de amostragem, número de amostras, número de subbandas. Isso depende de fatores como largura de banda do sinal a ser analisado, resolução desejada no tempo e na frequência, ? Wavelet decomposition spectral bands, ? Frequency resolution, ? Appropriate number of decomposition. O número de amostras necessário é dado por:

$$(16) \quad f_a = 2f_u$$

$$(17) \quad N = \frac{f_a}{f_r}$$

$$(18) \quad p_t = p_l + p_u$$

$$(19) \quad p_l \approx 2$$

$$(20) \quad p_u = \lceil \left[\frac{\log\left(\frac{f_a}{f_l}\right)}{\log(2)} \right] \rceil$$

onde N é o número de amostras, f_a é a frequência de amostragem, p_L é o número de decomposições a ser aplicado, f_r é a resolução em baixas frequências desejada, e f_u e f_l são as frequências máxima e mínima que se deseja analisar.

5. A TRANSFORMADA DE WAVELETS NO DIAGNÓSTICO DE FALHAS

A Transformada de Wavelets, em qualquer de suas versões, possibilita a análise de sinais não-periódicos, que é difícil com a Transformada de Fourier. Estudos (por exemplo, [KIM 2007, APENG 2004]) mostram que para tal aplicação ela é superior à Transformada de Fourier de Tempo Curto(STFT) e à Distribuição de Wigner-Ville (WVD).

A STFT apresenta dois inconvenientes principais:

perda de resolução em altas frequências por empregar uma janela de tempo de largura constante, devido ao chamado *Princípio da Incerteza* característico da Transformada de Fourier; e não usar uma base ortogonal, o que dificulta encontrar um algoritmo de cálculo eficiente para os coeficientes. Por isso, ela é usada muito pouco, tendo sua utilidade restrita a sinais quase-estacionários.

A WVD, por outro lado, tem boas características matemáticas, mas em alguns casos pode haver interferência entre os componentes, o que torna a interpretação do resultado muito difícil; a filtragem da interferência, por outro lado, resulta em perda de informação. Além disso, seu custo computacional é ainda maior que o da STFT.

A Transformada de Wavelets também apresenta algumas limitações: em primeiro lugar, como ela se origina em uma correlação, está sujeita a efeitos como embaçamento (*blurring*); em segundo lugar, aliasing e interferências podem ocorrer em alguns casos, embora com menos intensidade que com a WVD; finalmente, o espectro é bastante sensível a ruído.

A WPT é capaz ainda de detectar desvios na frequência dos sinais característicos de uma falha ao longo do tempo, proporcionando informação a respeito de aumento da tendência à falha; além disso, como determinados defeitos se manifestam em frequências conhecidas, a WPT pode ser gerada de maneira a mostrar de forma detalhada apenas as bandas mais interessantes, otimizando o custo computacional do monitoramento. A SGWT, por sua vez, vem sendo empregada cada vez mais, em função de seu custo mais baixo.

A primeira aplicação conhecida do uso de wavelets para diagnóstico de máquinas rotativas deve-se a Wang e McFadden, que as empregaram para analisar sinais de vibração de engrenagens.

6. METODOLOGIA DA PESQUISA

Na primeira fase do trabalho, particularizou-se o tema da pesquisa. Para tanto, dado o tema principal, uso da Transformada de Wavelet para análise de séries temporais, selecionou-se um grupo de 5 artigos técnicos de alto nível para constar da bibliografia de referência. O processo de pre-seleção encontra-se detalhado no item 6.1.1. A partir desse conjunto de artigos, optou-se por limitar a pesquisa às aplicações de diagnóstico de falhas em motores de indução, pelos seguintes motivos:

1. A disponibilidade de referências bibliográficas de alto nível.
2. A existência de interesse econômico no tema por parte da indústria.
3. A possibilidade e facilidade de aplicação prática do investigado, a ser explorada em trabalhos futuros.
4. A possibilidade de expandir o estudo, em trabalhos futuros, de forma a abarcar outros tipos de máquinas rotativas.

6.1. Bibliografia de referência. A bibliografia de referência foi organizada a partir de uma pre-seleção de artigos técnicos relevantes e de alto nível. O processo está descrito no item 6.1.1. Durante a pesquisa, material adicional foi incluído conforme a necessidade.

6.1.1. Artigos. Os artigos técnicos foram pre-selecionados de acordo com os seguintes critérios:

1. Ano de publicação: publicações mais recentes receberam prioridade.
2. Número de citações: artigos mais frequentemente citados receberam prioridade.
3. Propósito: procurou-se mesclar artigos de naturezas diversas.

Para tanto, foi necessário analisar apenas os metadados de cada um. Ao final do processo, os escolhidos foram os seguintes ³:

³A lista completa de arquivos encontra-se no anexo ??

- a) 4: Trata-se de uma revisão do assunto, e também é o artigo mais citado da lista. Com a sua escolha, o artigo 3, que também é uma revisão, foi descartado, apesar de também ostentar muitas citações.
- b) 7: Trata-se de outra revisão, mas muito mais recente, e que ainda assim possui bom número de citações. Sua inclusão teve o propósito de obter-se uma visão mais recente do tema tratado pelo anterior.
- c) 9: Trata-se de um artigo com bom número de citações e específico para diagnóstico de falhas em motores de indução.
- d) 19: Trata-se de um artigo pouco citado, mas bastante recente, e também específico para falhas em motores de indução. Sua inclusão teve o propósito de obter-se uma visão mais recente do tema tratado pelo anterior.
- e) 17: Trata-se de um artigo muito citado, não específico para motores de indução e sim para máquinas rotativas em geral. Sua inclusão teve o propósito de obter-se uma visão mais geral do assunto.

O conjunto de artigos pre-selecionado atende bem aos critérios de relevância e atualidade.

Para fins de documentação, o 7.1 apresenta todos os artigos cujos metadados foram examinados para a pre-seleção.

7. ANEXOS

7.1. Lista completa de artigos. A tabela e a lista que seguem apresentam os artigos cujos metadados foram analisados na fase de pre-seleção. Os artigos pre-selecionados estão realçados. O número de citações foi obtido no Google Scholar.

Número	Ano	Disponibilidade	Citações
1	2015	Gratuito	2
2	2013	ResearchGate	4
3	2004	ResearchGate	698
4	2006	Elsevier	1776
5	2005	Gratuito	10
6	2010	Gratuito	20
7	2014	ResearchGate	160
8	2008	Gratuito	56
9	2004	IEEE	134
10	2011	Gratuito	4
11	2007	ResearchGate	36
12	2011	Gratuito	25
13	2013	Gratuito	2
14	2015	ResearchGate	5
15	2013	Gratuito	2
16	2005	Gratuito	107
17	2007	Elsevier	244
18	2011	Gratuito	2
19	2014	Gratuito	5
20	2007	Gratuito	40
21	2001	Gratuito	5
22	2011	Gratuito	22
23	2009	ResearchGate	45
24	2005	Gratuito	15
25	2004	Gratuito	10
26	2002	Gratuito	28
27	2012	Gratuito	21
28	2004	Gratuito	169

1. Ruqiang Yan, Mengxiao Shan, Jianwei Cui e Yahui Wu - Mutual Information-Assisted Wavelet Function Selection for Enhanced Rolling Bearing Fault Diagnosis - Shock and Vibration, Vol. 2015, Article ID 794921.
2. Zhenyou Zhang, Yi Wang e Kesheng Wang - Intelligent fault diagnosis and prognosis approach for rotating machinery integrating wavelet transform, principal component analysis, and artificial neural networks - Journal of Advanced Manufacturing Technology, Sep. 2013.
3. PENG 2004

4. **Andrew K.S. Jardine, Daming Lin e Dragan Banjevic - A review on machinery diagnostics and prognostics implementing condition-based maintenance - Mechanical Systems and Signal Processing, Vol. 20, Issue 7, Oct. 2006, pp. 1483 a 1510**
5. Hongyu Yang - Automatic Fault Diagnosis of Rolling Element Bearings Using Wavelet Based Pursuit Features - School of Mechanical, Manufacturing and Medical Engineering, Queensland University of Technology, Oct. 2004
6. Lixin Gao, Zhiqiang Ren, Wenliang Tang, Huaqing Wang e Peng Chen - Intelligent gearbox diagnosis methods based on SVM, wavelet lifting and RBR - Sensors 2010, 10, pp. 4602 a 4621.
7. **Ruqiang Yan, Robert X. Gao, Xuefeng Chen - Wavelets for fault diagnosis of rotary machines: A review with applications - Signal Processing, Vol. 96, Part A, Mar. 2014, pp. 1 a 15**
8. Pratesh Jayaswal, A. K. Wadhwani e K. B. Mulchandani - Machine Fault Signature Analysis - International Journal of Rotating Machinery, Vol. 2008, Article ID 58398.
9. **T. W. S. Chow, Shi Hai - Induction machine fault diagnostic analysis with wavelet technique - IEEE Transactions on Industrial Electronics, Vol. 51, Issue 3, Jun. 2004, pp. 558 a 565**
10. Derek Kanneg, Wilson Wang - A Wavelet Spectrum Technique for Machinery Fault Diagnosis - Journal of Signal and Information Processing, 2011, 2, pp. 322 a 329.
11. Li Li, Liangsheng Qu, Xianghui Liao - Haar wavelet for machine fault diagnosis - Mechanical Systems and Signal Processing, Vol. 21, Issue 4, May 2007, pp. 1773 a 1786.
12. Khalaf Salloum Gaeid e Hew Wooi Ping - Wavelet fault diagnosis and tolerant of induction motor: A review - International Journal of the Physical Sciences Vol. 6(3), pp. 358-376, Feb. 2011

13. Pu Shi, Zheng Chen e Yuriy Vagapov - Wavelet Transform based Broken Rotor-bar Fault detection and Diagnosis Performance Evaluations - International Journal of Computer Applications, Vol. 69, No. 14, May 2013.
14. M. Kang, J. Kim e J. M. Kim - An FPGA-Based Multicore System for Real-Time Bearing Fault Diagnosis Using Ultrasampling Rate AE Signals - IEEE Transactions on Industrial Electronics, Vol. 62, Issue 4, Oct. 2014, pp. 2319 a 2329.
15. A. Santhana Raj e N. Murali - Morlet Wavelet UDWT Denoising and EMD based Bearing Fault Diagnosis - Electronics, Vol. 17, No. 1, Jun. 2013.
16. Ruqiang Yan e Robert X. Gao - An efficient approach to machine health diagnosis based on harmonic wavelet packet transform - Robotics and Computer-Integrated Manufacturing 21, 2005, pp. 291 a 301.
17. **Qiao Hu, Zhengjia He, Zhousuo Zhang, Yanyang Zi - Fault diagnosis of rotating machinery based on improved wavelet package transform and SVMs ensemble - Mechanical Systems and Signal Processing, Vol. 21, Issue 2, Feb. 2007, pp. 688 a 705**
18. Andrzej Klepka - Wavelet Based Signal Demodulation Technique for Bearing Fault Detection - Mechanics and Mechanical Engineering, Vol. 15, No. 4, 2011, pp. 63 a 71.
19. **Jeevanand Seshadrinath, Bhim Singh e Bijaya Ketan Panigrahi - Incipient Interturn Fault Diagnosis in Induction Machines Using an Analytic Wavelet-Based Optimized Bayesian Inference - IEEE Transactions on Neural Networks and Learning systems, Vol. 25, No. 5, May 2014.**
20. Jie Liu, Wilson Wang, Farid Golnaraghi e Kefu Liu - Wavelet spectrum analysis for bearing fault diagnostics - Measurement Science and Technology 19, 2008.
21. H. Ahmadi, R. Tafreshi, F. Sassani e G. Dumont - On the Performance of Informative

- Wavelets for Classification and Diagnosis of Machine Faults - Y. Y. Tang et al. (Eds.): Berlin, Springer-Verlag, 2001, pp. 369 a 381.
22. Yun-Jie Xu, Shu-Dong Xiu - A New and Effective Method of Bearing Fault Diagnosis Using Wavelet Packet Transform Combined with Support Vector Machine - Journal of Computers, Vol. 6, No. 11, Nov. 2011.
23. N. Saravanan e K.I. Ramachandran - Fault diagnosis of spur bevel gear box using discrete wavelet features and Decision Tree classification - Expert Systems with Applications, Vol. 36, Issue 5, Jul. 2009, pp. 9564 a 9573.
24. Jiri Vass e Cristina Cristalli - Optimization of Morlet Wavelet for Mechanical Fault Diagnosis - 12th International Congress on Sound and Vibration, Jul. 2005.
25. Loránd Szabó, Jeno Barna Dobai, Károly Ágoston Biró - Discrete Wavelet Transform Based Rotor Faults Detection Method for Induction Machines - International Journal of Engineering Research and Applications, Special Issue *International Conference on Industrial Automation and Computing*, Apr. 2014.
26. Howard A. Gaberson - The Use of Wavelets for Analyzing Transient Machinery Vibration - Sound and Vibration, Sep. 2002.
27. Hocine Bendjama, Salah Bouhouche e Mohamed Seghir Boucherit - Application of Wavelet Transform for Fault Diagnosis in Rotating Machinery - International Journal of Machine Learning and Computing, Vol. 2, No. 1, Feb. 2012.
28. Peter W. Tse, Wen-xian Yang e H.Y. Tam - Machine fault diagnosis through an effective exact wavelet analysis - Journal of Sound and Vibration 277, 2004, pp. 1005 a 1024.

REFERÊNCIAS

Obras consultadas

— Artigos —

- [AAYAZ 2014] E. AYZ, **A Review Study on Mathematical Methods for Fault Detection Problems in Induction Motors** : Balkan Journal of Electrical & Computer Engineering, 2014, Vol.2, No.3. Disponível em <http://dergipark.ulakbim.gov.tr/bajece/article/download/5000102024/5000095108>, acesso em 26/03/2016.
- [ABOUZIDA 2013] AHCÈNE BOUZIDA, Omar TOUHAMI e Radia ABDELLI, **Rotor Fault Diagnosis in Three Phase Induction Motors Using the Wavelet Transform** : International Conference on Control, Engineering & Information Technology (CEIT'13) Proceedings Engineering & Technology - Vol.1, pp. 186-191, 2013. Disponível em http://ipco-co.com/PET_Journal/presented\%20papers/095.pdf, acesso em 26/03/2016.
- [AKAHN 2010] M. Abdesesh Shafiel Kafey KHAN and M. Azizur RAHMAN, **Wavelet Based Diagnosis and Protection of Electric Motors**, in Fault Detection, Wei Zhang (Ed.), ISBN: 978-953-307-037-7, InTech, 2010.<http://www.intechopen.com/books/fault-detection/wavelet-based-diagnosis-and-protection-of-electric-motors>26/03/2016
- [ANGOTE 2014] Nabil NGOTE, Said GUEDIRA, Mohamed CHERKAOUI e Mohammed OUASSAID, **Diagnosis of Induction Motor Rotor Fault through Discrete Wavelet Transform Applied to Residual Current** : Jerzy Balicki (Ed.) - Advances in Applied and Pure Mathematics, ISBN: 978-960-474-380-3, pp. 390 a 396. Disponível em <http://www.wseas.us/e-library/conferences/2014/Gdansk/MATH/MATH-51.pdf>, acesso em 26/03/2016.
- [APENG 2004] PENG Z. K. e CHU F. L., **Application of the wavelet transform in machine condition monitoring and fault diagnostics: a review with bibliography** : Mechanical Systems and Signal Processing, Vol. 18, Issue 2, March 2004, pp. 199 a 221.. Disponível em <http://www.sciencedirect.com/science/article/pii/S088832700300075X>, acesso em 26/03/2016.
- [APEZZANI 2015] Carlos PEZZANI et. al., **Deteção de Barras Rompidas do Rotor Através da Proteção com Zero Ajustes**. Disponível em http://www.selinc.com.br/art_tecnicos/6512_Deteccao-de-Barras-Rompidas-do-Rotor-Atraves-da-Protecao-com-Zero-Ajustes.pdf, acesso em 26/03/2016.
- [APRAKASH 2014] Aditya PRAKASH, Vikash Ku. AGARWAL, Amit KUMAR, Bhaskra NAND, **A review on machine**

- condition monitoring and fault diagnostics using wavelet transform** : International Journal of Engineering Technology, Management and Applied Sciences September 2014, Volume 2 Issue 4, ISSN 2349-447684. Disponível em <http://www.ijetmas.com/admin/resources/project/paper/f201409151410798115.pdf>, acesso em 26/03/2016.
- [ASESHADRINATH 2014] Jeevanand SESHADRINATH, Bhim SINGH e Bijaya Ketan PANIGRAHI, **Incipient Interturn Fault Diagnosis in Induction Machines Using an Analytic Wavelet-Based Optimized Bayesian Inference** : IEEE Transactions on Neural Networks and Learning Systems, Vol. 25, No. 5, May 2014. Disponível em <http://210.30.190.120/ckwx/yuan/mhgzzd/201408250110.pdf>, acesso em 26/03/2016.
- [ASHI 2013 1] SHI Pu, CHEN Zheng, Yuriy VAGAPOV, **International Journal of Computer Applications, Volume 69, No.14, May 2013, pp. 36 a 43** : Wavelet Transform based Broken Rotor-bar Fault detection and Diagnosis Performance Evaluations. Disponível em <http://research.ijcaonline.org/volume69/number14/pxc3888033.pdf>, acesso em 26/03/2016.
- [ASHI 2013 2] SHI Pu, CHEN Zheng, Yuriy VAGAPOV, **International Journal of Computer Applications, Volume 69, No.14, May 2013, pp. 44 a** : WFault Detection and Diagnosis of Induction Machines based on Wavelet and Probabilistic Neural Network. Disponível em <http://research.ijcaonline.org/volume69/number14/pxc3888034.pdf>, acesso em 26/03/2016.
- [ASZABO 2004] Loránd SZABÓ, Károly Ágoston BIRÓ, Jenő Barna DOBAI, Dénes FODOR, József VASS, **Wavelet Transform Approach to Rotor Faults Detection in Induction Motors** : INES 2004. Disponível em http://www.ines-conf.org/ines-conf/75_INES2004.pdf, acesso em 26/03/2016.

— Figuras —

- [AFig1] . Disponível em <http://electrical-engineering-portal.com/download-center/books-and-guides/electrical-engineering/squirrel-cage-rotor-testing-methods>, acesso em 26/03/2016.

Obras complementares

- [BONNETT 1988] A. H. BONNETT e G. C. SOUKUP, **Analysis of Rotor Failures in Squirrel-Cage Induction Motors**, in IEEE Transactions on Industry Applications, vol. 24, no. 6, pp. 1124 a 1130, novembro/dezembro 1988.
- [CLAYPOOLE 1999] R. CLAYPOOLE, **Adaptive Wavelet Transform via Lifting**, in Thesis, Computer Engineering, Rice University, 1999..

- [COIFMAN 1992] R. R. COIFMAN, M. V. WICKERHAUSER, **Entropy-based algorithms for best basis selection**, in IEEE Transactions on Information Theory 38, 2, 1992, pp. 713 a 718.
- [DELEROI 1984] W. DELEROI, **Der Stabbruch im Käfigläufer eines Asynchronmotors Teil 1: Beschreibung mittels Überlagerung eines Störfeldes**, in Archiv Für Elektrotechnik, vol. 67, pp. 91–99, 1984.
- [HAMID 2002] E. Y. HAMID e KAWASAKI Z. I., **Wavelet based data compression of power system disturbances using the minimum description length data**, in IEEE Transactions on Power Delivery, Vol. 17, No. 2, 2002, pp. 460 a 466.
- [KIM 2007] B. S. KIM, S. H. LEE, M. G. LEE, J. NI, J.Y. SONG e C.W. LEE, **A comparative study on damage detection in speed-up and coast-down process of grinding spindle-typed rotor-bearing system**, in Journal of Materials Processing Technology, 187–188, 2007, pp. 30 a 36.
- [KLIMAN 1988] G. B. KLIMAN, R. A. KOEGL, J. STEIN, R. D. ENDICOTT e M. W. MADDEN, **Noninvasive Detection of Broken Rotor Bars in Operating Induction Motors**, in IEEE Transactions on Energy Conversion, vol. 3, no. 4, pp. 873 a 879, dezembro de 1988.
- [MALLAT 1989] S. MALLAT, **A theory of multiresolution signal decomposition: the wavelet representation**, in IEEE Transactions on Pattern Analysis and Machine Intelligence 11, 7, 1989, pp. 674 a 693.
- [PENROSE 2008] H. PENROSE, **Electrical Motor Diagnostics**, 2nd ed. Success by Design, maio de 2008.
- [SWELDENS 1998] W. SWELDENS, **The lifting scheme: a construction of second generation wavelets**, in SIAM Journal on Mathematical Analysis, 29, 2, 1998, pp. 511 a 546.